Probabilidades en R

Resumen de todo lo visto: cómo traducir el enunciado a R, probabilidad empírica, condicional, independencia, Bayes, densidades, modelos y gráficos. Convenciones: la base se llama `DF` (dos bases: `DFF` y `DFR`) y **todo resultado decimal se entrega con `round(..., 2)`**; los que solo pueden ser **enteros** (conteos) se responden **exactos**.

1. Plantilla de inicio

```
library(readr)
DF <- read_csv("archivo.csv")
# Columnas con ñ o tildes van entre comillas invertidas:  DF$`Año`
# Si sale error de codificación: guardar el script como UTF-8
```

2. Traducir el enunciado: ¿intersección, unión, complemento o condicional?

La clave es **leer la palabra que une los eventos**. Primero define cada evento como un vector lógico (TRUE/FALSE) y luego combínalos.

Si el enunciado dice…	Es…	Notación	En R
"A **y** B", "A **pero** B", "A **y además** B", "**ambos**", "**a la vez**", "que cumpla A **y que** cumpla B"	Intersección	$A \cap B$	`mean(A & B, na.rm = TRUE)`
"A **o** B", "**al menos uno** de los dos", "**alguno**", "A **o bien** B"	Unión	$A \cup B$	`mean(A | B, na.rm = TRUE)`
"**no** A", "**no es**…", "**excepto**", "**fuera de**", A con **barra encima** ($\bar{A}$)	Complemento	$\bar{A}$	`mean(!A, na.rm = TRUE)`
"**ni** A **ni** B", "no A **y** no B", "ninguno de los dos"	Complemento de la unión	$\bar{A} \cap \bar{B} = \overline{A \cup B}$	`mean(!A & !B, na.rm = TRUE)`
"**no ambos**", "no ocurren A y B a la vez", barra sobre ($A \cap B$)	Complemento de la intersección	$\overline{A \cap B} = \bar{A} \cup \bar{B}$	`mean(!(A & B), na.rm = TRUE)`
"**exactamente uno**", "A o B **pero no ambos**"	Diferencia simétrica	$(A \cap \bar{B}) \cup (\bar{A} \cap B)$	`mean(xor(A, B), na.rm = TRUE)`
"A **dado que** B", "**si se sabe que** B", "**entre los que** cumplen B", "**de los que** B", "**sabiendo que**", "**condicional**"	Condicional	$P(A \mid B)$	`mean(A[B], na.rm = TRUE)`

⚠ **La trampa de la barra vertical "|"**
En el **enunciado (matemática)**, `P(A | B)` se lee "A **dado que** B" → es **CONDICIONAL**.
En **R**, `A | B` significa "A **o** B" → es **UNIÓN**.
Por eso **nunca** copies P(A | B) como `mean(A | B)`. La condicional se escribe `mean(A[B], na.rm = TRUE)` (los corchetes = "solo entre los que cumplen B").

Dice	Significa	R correcto	R incorrecto
P(X | Y)	X dado Y	`mean(X[Y], na.rm=TRUE)`	`mean(X | Y)`
P(X ∪ Y)	X o Y	`mean(X | Y, na.rm=TRUE)`	`mean(X[Y])`

Truco: si ves **"dado", "sabiendo", "entre los que"** → corchetes `[ ]`. Si ves **"o", "al menos uno"** → `|`.

Palabras para definir cada evento (comparaciones)

Enunciado	R	Enunciado	R
más de 10000	`x > 10000`	menos de 200	`x < 200`
al menos / como mínimo 20000	`x >= 20000`	**a lo sumo** / como máximo 5	`x <= 5`
es del mes de mayo	`DF$Mes == "Mayo"`	no es del año 2020	`DF$`Año` != 2020`
entre las cinco mejores (ranking)	`DF$Pos <= 5`	no entre las 5 mejores pero sí entre las 100	`DF$Pos > 5 & DF$Pos <= 100`
entre 12.5 y 50	`x > 12.5 & x < 50`	pertenece a una lista	`x %in% c("a","b")`

Cómo leer las barras (complementos) en una expresión

La barra niega **todo lo que queda debajo de ella**. Traduce de adentro hacia afuera y pon paréntesis donde termina la barra:

```
# P( barra(X ∩ Y)  ∩  barra(U ∪ O) )
mean(!(X & Y) & !(U | O), na.rm = TRUE)

# P( Ū ∩ Ȳ )   (barra solo sobre cada letra)
mean(!U & !Y, na.rm = TRUE)
```

Leyes de De Morgan (sirven para comprobar): `!(A & B)` = `!A | !B` y `!(A | B)` = `!A & !B`. Si al calcular ambas formas da el mismo número, lo hiciste bien.

2b. Conteo (combinatoria)

Pregunta clave	Técnica	Fórmula	En R
¿Importa el orden? **NO** ("conjunto", "grupo", "comité", "seleccionar")	Combinaciones	(n sobre k) = n! / (k!(n−k)!)	`choose(n, k)`
¿Importa el orden? **SÍ** ("1º, 2º, 3º", "podio", "puestos distintos")	Variaciones	V(n,k) = n! / (n−k)!	`factorial(n)/factorial(n-k)`

Ordenar a **todos** los n	Permutaciones	n!	`factorial(n)`

```
# Lab 2 P4: ¿de cuántas maneras se obtiene el CONJUNTO de 32 corredoras de 117?
choose(117, 32)        # orden NO importa → (117 sobre 32)
```

Situación	En R
Repartir n en g grupos **distintos** de k cada uno (carreras 1, 2, 3, 4)	`factorial(32)/factorial(8)^4` = `choose(32,8)*choose(24,8)*choose(16,8)*choose(8,8)`
Una persona fija: elijo su grupo y sus compañeras, luego el resto	`choose(4,1)*choose(31,7)*choose(24,8)*choose(16,8)` (da lo mismo)
Que 2 personas concretas ocupen los 2 primeros puestos de una carrera de 8	`1/choose(8,2)` = 1/28

Probabilidad clásica (todos los casos igual de probables): P = casos favorables / casos posibles, ambos contados con `choose` o `factorial`.

3. Probabilidad empírica

Probabilidad empírica = proporción de filas que cumplen el evento. La media de un vector TRUE/FALSE es la proporción de TRUE.

```
X <- DF$Streamers > 10000
Y <- DF$PromCan < 200
round(mean(X, na.rm = TRUE), 2)          # P(X)
round(mean(X & Y, na.rm = TRUE), 2)      # P(X ∩ Y)
round(mean(X | Y, na.rm = TRUE), 2)      # P(X ∪ Y)
sum(X, na.rm = TRUE)                     # casos favorables (conteo)
```

NA: si una variable tiene datos faltantes, `na.rm = TRUE` ignora esas filas. Alternativa si el sistema marca error: filtrar antes `DF <- DF %>% filter(!is.na(PromCan))`.

4. Probabilidad condicional, independencia y disjuntos

```
round(mean(X[Y], na.rm = TRUE), 2)                          # P(X | Y)  forma corta
round(sum(X & Y, na.rm = TRUE) / sum(Y, na.rm = TRUE), 2)  # P(X | Y) = P(X ∩ Y) / P(Y)
round(mean(E[!M], na.rm = TRUE), 2)                         # P(E | no M)
```

Opción	Cómo decidir (redondeando a 2 decimales)
Independientes	P(A | B) = P(A). Saber B no cambia la probabilidad de A. `round(mean(A[B],na.rm=TRUE),2) == round(mean(A,na.rm=TRUE),2)`
Dependientes	P(A | B) ≠ P(A).
Disjuntos (mutuamente excluyentes)	No pueden ocurrir juntos: P(A ∩ B) = 0 → `sum(A & B, na.rm = TRUE) == 0`
Nulos	El evento nunca ocurre: P(A) = 0.

5. Probabilidad total y Bayes (datos teóricos de un "experto")

Si A, B, C reparten todos los casos y te dan P(V|A), P(V|B), P(V|C), P(A), P(B), P(C):

```
PV  <- 0.90*0.025 + 0.30*0.475 + 0.05*0.500   # Probabilidad total: P(V) = Σ P(V|i)·P(i)
round(PV, 2)                                   # 0.19
round(0.90*0.025 / PV, 2)                      # Bayes: P(A|V) = P(V|A)·P(A) / P(V) = 0.12

# Comparar con lo EMPÍRICO
A <- DF$Pos <= 5;  V <- DF$Streamers >= 20000
round(mean(V, na.rm = TRUE), 2)                # 0.31
round(mean(A[V], na.rm = TRUE), 2)             # 0.21
```

> Teórico **menor** que lo observado (de algo "bueno") → el experto es **más pesimista**. Teórico **mayor** → **más optimista**.

6. Variables continuas: función de densidad por partes

```
# 1) Definir la densidad por partes con ifelse (sin la k)
g <- function(x) ifelse(x > 0 & x <= 1, 4 - 3*(1 - x)^2,
                 ifelse(x > 1 & x <= 3, (x - 3)^2, 0))
# 2) k para que el área total sea 1
k <- 1 / integrate(g, 0, 3)$value;  f <- function(x) k * g(x)
round(k, 2)                                            # 0.18
# 3) Probabilidad = área bajo f
round(integrate(f, 1, 3)$value, 2)                     # P(X > 1) = 0.47
# 4) Valor esperado y desviación estándar
E  <- integrate(function(x) x   * f(x), 0, 3)$value
E2 <- integrate(function(x) x^2 * f(x), 0, 3)$value
S  <- sqrt(E2 - E^2)
round(E, 2); round(S, 2)                               # 1.01 y 0.56
# 5) Mediana teórica: F(m) = 0.5
round(uniroot(function(m) integrate(f, 0, m)$value - 0.5, c(0, 3))$root, 2)   # 0.96
# 6) Centralidad: CV = S/E*100 → si > 30% usar MEDIANA, si < 30% PROMEDIO
round(S / E * 100, 2)                                  # 55.52 → mediana
```

7. Modelos de probabilidad (d, p, q, r)

Prefijo	Qué da	Ejemplo
`d`	P(X = x) (discreta) o densidad (continua)	`dgeom(0, p)`, `dgamma(x, sha, rat)`
`p`	Acumulada P(X ≤ x)	`pgeom(m, p)`
`p(..., lower.tail = FALSE)`	Cola superior P(X > x)	`pgamma(50, sha, rat, lower.tail = FALSE)`
`q`	Cuantil (Q1, mediana, Q3)	`qgamma(c(.25,.5,.75), sha, rat)`
`r`	Simula n valores	`set.seed(1); rgeom(5, p)`

Modelo	Parámetro desde la media m	Media / sd teóricas	Funciones
Geométrico (R cuenta fracasos 0,1,2…)	`p <- 1/(m + 1)`	(1−p)/p ; `sqrt((1-p)/p^2)`	dgeom, pgeom

Poisson	`lambda <- m`	λ ; `sqrt(lambda)`	dpois, ppois
Binomial (n intentos)	`p <- m/n`	np ; `sqrt(n*p*(1-p))`	dbinom, pbinom
Exponencial	`rate <- 1/m`	1/rate ; 1/rate	dexp, pexp
Normal	`mu <- m; s <- sd(x)`	μ ; σ	dnorm, pnorm, qnorm
Gamma	shape, rate (del enunciado)	shape/rate ; `sqrt(shape)/rate`	dgamma, pgamma, qgamma

Continua: P(a < X < b) = `pgamma(b, ...) - pgamma(a, ...)` y P(X ≥ a) = P(X > a).
Discreta: P(X ≥ a) = `ppois(a - 1, lambda, lower.tail = FALSE)` (hay que restar 1).

Validar un modelo (¿es bueno?)

```
m <- mean(DF$Streamers, na.rm = TRUE);  p <- 1/(m + 1)
round(sqrt((1 - p)/p^2), 2)                        # sd teórica   34055.08
round(sd(DF$Streamers, na.rm = TRUE), 2)           # sd empírica  61174.47
round(pgeom(m, p, lower.tail = FALSE), 2)          # P teórica(X > media) 0.37
round(mean(DF$Streamers > m, na.rm = TRUE), 2)     # P empírica           0.23
```

Si la sd y las probabilidades teóricas se parecen a las empíricas → el modelo **es bueno**. Si la sd teórica es mucho menor → **no es bueno**, "tiene una variabilidad mucho menor" (mucho mayor → "variabilidad mucho mayor").

8. Gráfica comparativa: muestra vs modelo

```
hist(Z, prob = TRUE, breaks = seq(0, 300, 12.5))              # histograma en densidad
boxplot(Z, horizontal = TRUE, add = TRUE, at = -0.0015, boxwex = 0.002)
lines(0:300, dgamma(0:300, shape = sha, rate = rat), col = "red", lwd = 2)
abline(v = c(mean(Z, na.rm = TRUE), sha/rat, qgamma(c(.25,.5,.75), sha, rat)))
```

Lo que ves	Conclusión
Cola larga a la derecha, atípicos a la derecha en el boxplot	Sesgada a la derecha (media > mediana)
Borde derecho de la caja (Q3 empírico) a la derecha de c	P empírica(X > c) ≥ 0.25
Línea del Q3 teórico a la derecha de c	P teórica(X ≥ c) ≥ 0.25
Líneas Q1–Q3 teóricas dentro de la caja	IQR teórico < IQR empírico
Tamaño efectivo, máximos exactos, probabilidades con decimales	No se leen en la gráfica: requieren cálculo

9. Ejercicios resueltos (EF · Twitch)

P1 · Probabilidades empíricas

```
X <- DF$Streamers > 10000;  Y <- DF$PromCan < 200
U <- DF$Mes == "Mayo";      O <- DF$`Año` != 2020
round(mean(X, na.rm = TRUE), 2)                    # 0.51
round(mean(Y, na.rm = TRUE), 2)                    # 0.64
round(mean(U, na.rm = TRUE), 2)                    # 0.09
round(mean(O, na.rm = TRUE), 2)                    # 0.89
round(mean(X & Y, na.rm = TRUE), 2)                # "y"            → 0.13
round(mean(U | O, na.rm = TRUE), 2)                # "o"            → 0.89
round(mean(!U & !Y, na.rm = TRUE), 2)              # "no … y no …"  → 0.32
round(mean(!(X & Y) & !(U | O), na.rm = TRUE), 2)  # barras         → 0.08
```

P2 · Condicional e independencia

```
E <- DF$Mes == "Enero";  M <- DF$`Año` == 2024
round(mean(X[Y], na.rm = TRUE), 2)    # 0.24 vs P(X) 0.51 → dependientes
round(mean(E[!M], na.rm = TRUE), 2)   # 0.08 vs P(E) 0.08 → independientes
```

P3 · Probabilidad total y Bayes

```
# Teórico: P(V) 0.19, P(A|V) 0.12 · Empírico: 0.31 y 0.21 → experto más pesimista
```

P4 · Densidad por partes

```
# k 0.18 · P(X>1) 0.47 · E 1.01 h · sd 0.56 h · CV 55.52% → la mediana muestral
```

P5 · Modelo geométrico

```
# media 34054.58 · sd teórica 34055.08 · P(X>media) 0.37
# sd empírica 61174.47 · P empírica 0.23 → no es bueno: variabilidad mucho menor
```

P6 · Gráfica comparativa (gamma)

```
# Marcar: sesgada a la derecha · P emp(Z>50) ≥ 0.25 (0.28) · P teo(Z≥50) ≥ 0.25 (0.27)
# No marcar: IQR teórico (33.78) < empírico (35.74) · n y máximo / 0.59 no se leen en la
gráfica
```

Lab 2 · P4 a P8 (Atletismo: conteo y probabilidad clásica)

```
table(DF$País)[c("Perú", "Guatemala", "Trinidad")]          # 3, 1, 2
choose(117, 32)                                            # P4: conjunto de 32 de 117
round(sum(DF$País == "Perú") / nrow(DF), 2)                # P5: 3/32 = 0.09
factorial(32) / factorial(8)^4                             # P6: = choose(32,8)…
choose(8,8) = 4·choose(31,7)…
# P7: 1 sola guatemalteca → probabilidad 1
round(1 / choose(8, 2), 2)                                 # P8: 1/28 = 0.04
```

EA2 · Toyocars (autosseminuevos.csv, DFL = drop_na(DF)) · P1 a P8

Pregunta	Clave	En R	Resp.
P1 HILUX y Año Modelo 2021	Intersección "y"	`mean(DFL$`Año Modelo` == 2021 & DFL$Modelo == "HILUX")`	0.09

P2 3 eléctricos y 3 no de 9 (5+4), pide 6	Hipergeométrica (sin reposición)	`dhyper(3, 5, 4, 6)`	0.48
P3 P(mujer | automático)	Tabla 2×2 con conteos: H auto 300, M auto 200−150 = 50	`50 / (300 + 50)`	0.14
P4 P(dólares | hombre sin gusto por eléctricos)	Bayes; P(D) de `table(DFL$Genero, DFL$Moneda)` = 635/700	`0.75*pD/(0.75*pD + 0.5*(1-pD))`	0.94
P5 "al menos uno" compra	1 − P(ninguno)	`1 - prod(1 - c(.2,.3,.4,.5))`	0.832
P6 V/F	Independiente ≠ excluyente · resta P(A∩B) · Bernoulli = Binomial n=1	—	FFF
P7 "a lo más 5" jurídicas de 20 con reposición	Binomial, p = 256/900	`pbinom(5, 20, 256/900)`	0.48*
P8 revisar 7 hasta el 1er automático	Geométrica: 6 fracasos	`dgeom(6, 36/90)`	0.02

* 0.48 no figura entre las opciones (0.50 fue marcada incorrecta).

Frases de distribuciones: "elige k de un grupo SIN reposición" → hipergeométrica (`dhyper(x, m, n, k)`) · "hasta encontrar el primero" → geométrica (`dgeom(k-1, p)`) · "de n seleccionados con reposición, a lo más x" → binomial (`pbinom(x, n, p)`) · "al menos x" → `1 - pbinom(x-1, n, p)` · "al menos uno" de varios independientes → `1 - prod(1 - p)`.

10. Receta rápida para el examen

Paso	Qué hacer
1	Define cada evento con una letra: `X <- DF$Var > valor` (cuidado con "al menos" = `>=`).
2	Subraya la palabra que une: **y** → `&` · **o** → `|` · **no / ni** → `!` · **dado que** → `[ ]`.
3	Si hay barras, pon paréntesis donde termina cada barra y antepón `!`.
4	Calcula con `round(mean(..., na.rm = TRUE), 2)`.
5	Para comparar (independencia, modelo bueno, optimista/pesimista), compara los valores ya redondeados a 2 decimales.